$$\underset{M\times N}{Y} = \underset{M\times L}{A(\mu)}\ \underset{L\times N}{\Psi} + \underset{M\times N}{N}$$ L个信源

干脆把所有角度都采个样，得到一个已知的A

然后X的某些行为信号，其余行均为0（称X行稀疏）

这样信号和角度的信息都蕴含在X里

转化为CS中的信号复原问题

$$= \underset{M\times K}{A(\nu)}\ \underset{K\times N}{X} + \underset{M\times N}{N}$$

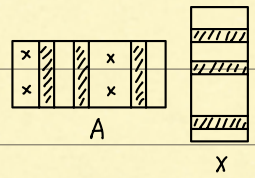

每一拍 $y = Ax + n$

$$\min \frac{1}{2}\|Ax - y\|_2^2 + \lambda\|x\|_1$$ λ越大 越稀疏

不能保证x完全稀疏

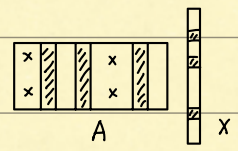

当有多个观测时，矩阵形式

$$\min_X \frac{1}{2}\|AX - Y\|_F^2 + \lambda\|X\|_{2,1}$$

$$\|X\|_{2,1} = \sum_{k=1}^{K}\|x_k\|_2$$ x_k表示X的第k行　　$l_{2,1}$范数也可换成$l_{\infty,1}$

分格数K越大分辨率越高

采样数N越大估计越准，但计算复杂度也要考虑

这里用 gridless signal reconstruction，或称 atomic norm minimization ???

$$\min_X \frac{1}{2}\|AX - Y\|_F^2 + \lambda\sqrt{N}\|X\|_{2,1}$$ 加个$\sqrt{N}$对结果无影响

等价于凸问题（SPARROW）

$$\min_{S\in D_+} Tr\{(ASA^H + \lambda I_M)^{-1}\hat{R}\} + Tr(S), \quad \hat{R} = \frac{1}{N}YY^H$$

$$X = SA^H(ASA^H + \lambda I_M)^{-1}Y$$

[证] 令s_k表示第k个信号的幅值（大概率没信号）

$s_k^2 = \frac{1}{N}\|x_k\|_2^2 = \frac{1}{N}x_k x_k^H$，　$S = diag(s_k)$ 真值中其中L个非零　　注意 $S \neq \frac{1}{N}XX^H$

若把信号x_k分解为幅值γ_k和信号向量g_k　$x_k = \gamma_k g_k$

由 $\|x_k\|_2 = |\gamma_k|\cdot\|g_k\|_2 \leq \frac{1}{2}(|\gamma_k|^2 + \|g_k\|_2^2)$　当且仅当$|\gamma_k| = \|g_k\|_2$时取等

$\|x_k\|_2 = \min \frac{1}{2}(|\gamma_k|^2 + \|g_k\|_2^2)$

s.t. $x_k = \gamma_k g_k$

s.t. $x_k = \gamma_k g_k$

当有许多观测 $\{x_k\}_{k=1}^{K}$ 时 $X = \Gamma G$

$$X = (x_k)_{K\times N},\quad \Gamma = diag(\gamma_1 \cdots \gamma_K),\quad G = (g_k)_{K\times N}$$

$$\|X\|_{2,1} = \sum_{k=1}^{K} \|x_k\|_2 = \min \frac{1}{2}(\|\Gamma\|_F^2 + \|G\|_F^2)$$

$$\text{s.t.}\quad X = \Gamma G$$

代入 X 和 $\|X\|_{2,1}$ 可得

$$\min_{\Gamma, G} \frac{1}{2}\|A\Gamma G - Y\|_F^2 + \frac{1}{2}\lambda\sqrt{N}(\|\Gamma\|_F^2 + \|G\|_F^2)$$

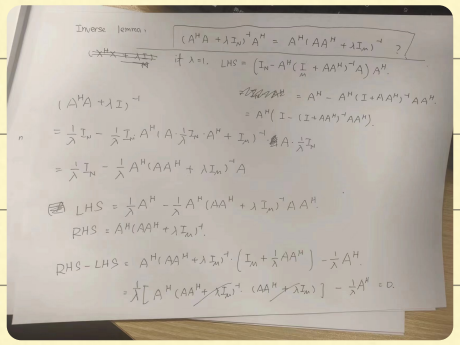

How to prove

$$(A^HA + \lambda I_N)^{-1}A^H = A^H(AA^H + \lambda I_M)^{-1}$$

当给定 Γ 时，求 G 即最小二乘岭回归

$$\hat{G} = (\Gamma^H A^H A\Gamma + \lambda\sqrt{N} I_K)^{-1}\Gamma^H A^H Y$$

利用矩阵逆引理

$$\hat{G} = \Gamma^H A^H (A\Gamma\Gamma^H A^H + \lambda\sqrt{N} I_M)^{-1} Y$$

此时代入 $\hat{G}$，得

$$\min_{\Gamma} \frac{1}{2}\lambda\sqrt{N}\,Tr\{(A\Gamma\Gamma^H A^H + \lambda\sqrt{N} I_M)^{-1} YY^H\} + \frac{1}{2}\lambda\sqrt{N}\,Tr\{\Gamma\Gamma^H\}$$

令 $S = diag(s_1 \cdots s_K) = \frac{1}{\sqrt{N}}\Gamma\Gamma^H$，显然 $s_k = \frac{1}{\sqrt{N}}|\gamma_k|^2 = \frac{1}{\sqrt{N}}|\gamma_k|\|g_k\|_2 = \frac{1}{\sqrt{N}}\|x_k\|_2$

则 $\min_{S} Tr\{(ASA^H + \lambda I_M)^{-1}\hat{R}\} + Tr(S)$

其中 $X = \hat{\Gamma}\hat{G} = \hat{S}A^H(ASA^H + \lambda I_M)^{-1}Y$

等价的半正定规划（SDP）

$$\min_{S, U_N} \frac{1}{N}Tr(U_N) + Tr(S)$$

U_N 是 Hermition 矩阵

$$\text{s.t.}\quad \begin{bmatrix} U_N & Y^H \\ Y & ASA^H + \lambda I_M \end{bmatrix} \succeq 0$$

$$S \in D_+$$

[证] $Tr\{(ASA^H + \lambda I_M)^{-1}\hat{R}\}$

$\hat{R} = \frac{1}{N}YY^H$

$= \frac{1}{N}Tr\{(ASA^H + \lambda I_M)^{-1}YY^H\}$

$Tr(AB) = Tr(BA)$

$= \frac{1}{N}Tr\{Y^H(ASA^H + \lambda I_M)^{-1}Y\}$

若取 $U_N = Y^H(ASA^H + \lambda I_M)^{-1}Y$，则顺理成章

为了化成 SDP 标准形式

这里令 $U_N \succeq Y^H(ASA^H + \lambda I_M)^{-1}Y$

注意到 ASA^H 即 Toeplitz 矩阵，故令 $Toep(u) = ASA^H$

可写作

$$\min_{u, U_N} \frac{1}{N}Tr(U_N) + \frac{1}{M}Tr(Toep(u))$$

U_N 是 Hermition 矩阵

$$\text{s.t.}\quad \begin{bmatrix} U_N & Y^H \\ Y & Toep(u) + \lambda I_M \end{bmatrix} \succeq 0$$

$$Toep(u) \succeq 0$$

因为先估计 Toeplitz 矩阵再求 A，便避免了分网格，故为连续 CS

Toeplitz 矩阵

$A = (a(\theta_1)\ a(\theta_2)\ \cdots\ a(\theta_K))$

$a(\theta_k) = \exp\{-j\pi \vec{r}\cos\theta_k\}$

因为ULA中 $\vec{r} = (0, 1, \cdots, M-1)$，故A是范德蒙矩阵

假设 $K \le M$

$A = \begin{bmatrix} 2 & 3 \\ 2^2 & 3^2 \end{bmatrix}$，$S = \begin{bmatrix} 10 & \\ & 100 \end{bmatrix}$

$ASA^T = 10 \times \begin{bmatrix} 2 \\ 2^2 \end{bmatrix} (2\ 2^2) + 100 \times \begin{bmatrix} 3 \\ 3^2 \end{bmatrix} (3\ 3^2)$

$= 10 \times \begin{bmatrix} 2^2 & 2^3 \\ 2^3 & 2^4 \end{bmatrix}$

$\underset{M\times K}{A}SA^H$ 是Hermitian的Toeplitz矩阵

Toeplitz：各对角线都相等

令第一行向量记为 u，该矩阵记为 $Toep(u)$

$$rank(Toep(u)) = K$$

在DOA问题中，我们先得到 u 和 $Toep(u)$，要恢复A和S

这个逆向过程称范德蒙分解

$$Toep(u) = ASA^H = \sum_{k=1}^{K} s_k a(\theta_k) a^H(\theta_k)$$

有许多方法，先获得 θ_k，也就明确了A，

进而求解 $As = u$ 可得幅值 $s = (s_1 \cdots s_K)^T$

这样 $Toep(u) = ASA^H$ 便可视作一个整体待优化即可

求解得 $\tilde{u}$，则信源数 $\hat{L} = rank(Toep(\hat{u}))$

稀疏　on-grid　$l_{2,1}$ 优化　$\min \frac{1}{2}\|X - AS\|_F^2 + \lambda \|X\|_{2,1}$

协方差估计

$R_0 = ASA^H$ 然后再 DOA　对称、正定、Toep、定秩

信息几何方法
- KL　$\min d_{KL}(\hat{R}, R_0)$
  $\text{s.t. } R_0 \in T_+ \cap H$
- Wasserstein　$\min d_{WG}(\hat{R}, R_0) - \mu \log\det R_0$
  梯度下降

$R_0 = ASA^H$

$\mathrm{vec} R_0 = (A^* \odot A) P$

可视为阵列位于 $(\bar{d}_m - \bar{d}_n) d_0$ 、差分协阵

稀疏
- on-grid　SPICE
- gridless　Atomic l_0 Norm

SPARROW 由 $l_{2,1}$ 而来

$\min \mathrm{Tr}\{(ASA^H + \lambda I)^{-1} \hat{R}\} + \mathrm{Tr}(S)$

$\text{s.t. } S \in D^+$